UNIVERSITE
DE LIMOGES

FACULTE DES SCIENCES
ET TECHNIQUES

INTELLIGENCE
ARTIFICIELLE

Filière : Master Mathématiques et Applications, Parcours ACSYON

Projet d'Intelligence Artificielle

Rédigé par :

Rami MECHI

Cleque Marlain MBOULOU

Professeur de la matière :

Karim TAMINE

Année académique 2022-2023

TABLE DES MATIÈRES

CHAPITRE

1

TP1: ALGORITHME DES K PLUS PROCHES VOISINS ET PERCEPTRON

1.1 Algorithme des K plus proches voisins

En intelligence artificielle, plus précisément en apprentissage automatique, la méthode des k plus proches voisins(KPPV) est une méthode d'apprentissage supervisé, c'est-à-dire qu'on va considérer un training set (ensemble de données) qui va surveiller notre apprentissage.

1.1.1 Description du problème

Notre problème est assez simple : on relève sur des individus de différentes classes 0 ou 1 des paramètres dans $\mathbf{R}^2$. On sait donc que pour tel individu de telle classe, on a tels paramètres. L'objectif est de pouvoir prévoir à quelle classe appartient un nouvel objet uniquement à l'aide de ses paramètres.
Le dataset est généré de la maniere suivante :

La première classe est composée de 128 individus et est associée à la fonction de densité de la loi normale $\mathcal{N}_2((4,4)^T, I_2)$:

$$f(x) = \frac{1}{2\pi}\exp\left\{-\frac{1}{2}\left(x-\begin{pmatrix}4\\4\end{pmatrix}\right)^T\begin{bmatrix}1&0\\0&1\end{bmatrix}^{-1}\left(x-\begin{pmatrix}4\\4\end{pmatrix}\right)\right\}$$

La seconde classe est composée de 128 individus et est associée à la fonction de densité de la loi normale $\mathcal{N}_2((-4,-4)^T, 4I_2)$:

$$f(x) = \frac{1}{8\pi}\exp\left\{-\frac{1}{2}\left(x-\begin{pmatrix}-4\\-4\end{pmatrix}\right)^T\begin{bmatrix}4&0\\0&4\end{bmatrix}^{-1}\left(x-\begin{pmatrix}-4\\-4\end{pmatrix}\right)\right\}$$

La création sous python donne :

```
# Données de test
mean1 = [4, 4]#moyenne de la distribution
cov1 = [[1, 0], [0, 1]] # Matrice de covariance de la distribution
data1 = np.transpose(np.random.multivariate_normal(mean1, cov1, 128))
mean2 = [-4, -4]
cov2 = [[4, 0], [0, 4]] # Matrice de covariance de la distribution.
                        #Elle doit être symétrique et semi-définie positive pour un échantillonnage correct.
data2 = np.transpose(np.random.multivariate_normal(mean2, cov2, 128))
data=np.concatenate((data1, data2), axis=1)
oracle=np.concatenate((np.zeros(128),np.ones(128)))#Liste des classe
```

1.1.2 Analyse

Afin, de déterminer les k plus proches voisin à un point x, il nous faut évaluer la distance entre ce point et tous les autres points données d'apprentissage. Pour se faire nous avons créée une fonction qui correspond à la norme 2 :

```
def distance_euclidienne(point1,point2):
    d_carre=(point1[0]-point2[0])**2+(point1[1]-point2[1])**2
    return sqrt(d_carre)
```

Nous allons ensuite déterminé grâce à notre algorithme KPPV, la classe à laquelle appartient l'individu x :

Algorithme KPPV :
1. Déterminer les distance entre x et tous les points de l'ensemble d'apprentissage
2. Ranger ces distances dans une liste dist
3. Récupérer les indices des distance triées par ordre croissant
4. Récuperles K premiers et les ranger dans une liste
5. Déterminer la classe de chaque indice voisin à x
6. Compter les indices de même classe
7. La classe de x est la classe majoritaire

Implémentation sous Python

```
def kppv_i(x,appren,oracle,K):
    dist   = []
    indice = []
    l      = []
    t      = 0


    classe=0 # On initialise la classe à 0 dans le cas contraire à la suite
    for j in range(len(appren[0])):

        d = distance_euclidienne(appren[:,j],x) # calcul la distance euclidienne entre le point x [:,i] et appren[:,j]
        dist.append((d))# la fonction __.append() remplie la liste_distance_a_xi entre le point x[:,i] et tout les points
                        #de appren

        #l=sorted(dist) #trie la liste par autre croissant des distances
    l = np.argsort(dist) # renvoie les indices des distances triées par ordre croisant

    for k in range(K):
        indice.append((l[k]))# On construit une liste contenant les indices des k plus proche voisins de x

    for j in range(K):
        if(oracle[indice[j]]==1):
            t = t+1 # On compte ceux qui sont de classe 1

    if(t>=int(K/2)+1):# On vérifie  si ceux qui sont de classe 1 sont en majorité
        classe=1  # On ce cas la  classe prend la valeur 1
    return classe
```

Nous appliquons alors notre algorithme avec les données test :

```
test1=np.transpose(np.random.multivariate_normal(mean1, cov1, 64))
test2=np.transpose(np.random.multivariate_normal(mean2, cov2,64))
test=np.concatenate((test1,test2), axis=1)
```

Il suffit donc de faire une boucle qui parcours les données test :

```
def kppv(test,appren,oracle,K):
    clas=[]
    for i in range(len(test[0])):
        classe=kppv_i(test[:,i],appren,oracle,K)# On détermine la classe de chaque élements de notre ensemble de test
        clas.append((classe)) # Puis on ajoute cette classe dans uns liste
    clas=np.array(clas) # Puis que les données renvoyées doivent être dans un tableau, on converti la liste en tableau numpy
    #print(len(clas))
    return (clas)
```

On a les resultats suivants :

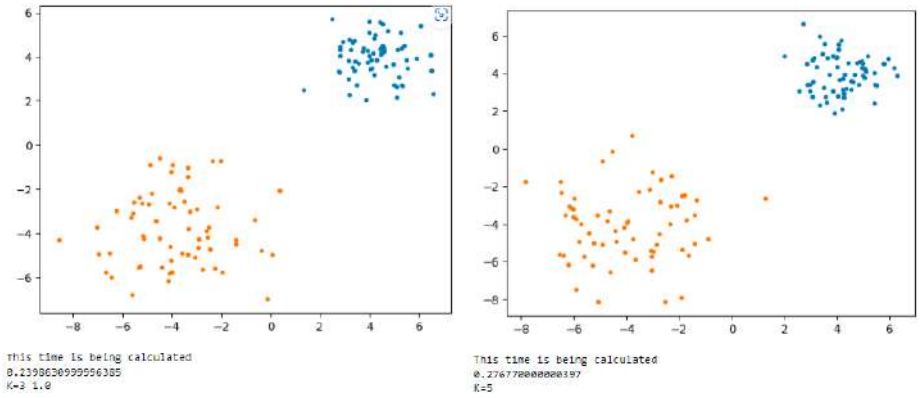

Ils ont identique car les points de nos données test tels que le 68 premiers sont de classe 0 et les 68 derniers de classe 1. Ainsi on crée un tableau que l'on nomme *orace* dont les 68 premieres entrées sont des 0 et les 68 dernieres des 1, puis on calcul l'accuracy.

```
from sklearn import metrics
accuracy = metrics.accuracy_score(clas, orace)
print(accuracy)
```

1.0

1.2 Perceptron

Le perceptron est un algorithme d'apprentissage supervisé de classifieurs binaires (c'est-à-dire séparant deux classes). Il a été inventé en 1957 par Frank Rosenblatt1 au laboratoire d'aéronautique de l'université Cornell. Il s'agit d'un neurone formel muni d'une règle d'apprentissage qui permet de déterminer automatiquement les poids synaptiques de manière à séparer un problème d'apprentissage supervisé. Si le problème est linéairement séparable, un théorème assure que la règle du perceptron permet de trouver une séparatrice entre les deux classes.

1.2.1 Description du problème

Notre objectif est de trouver une droite qui sépare au mieux les donnnées de classe 1 et celles de classe 2. La règle d'apprentissage d'un perceptron est la descente du gradient.

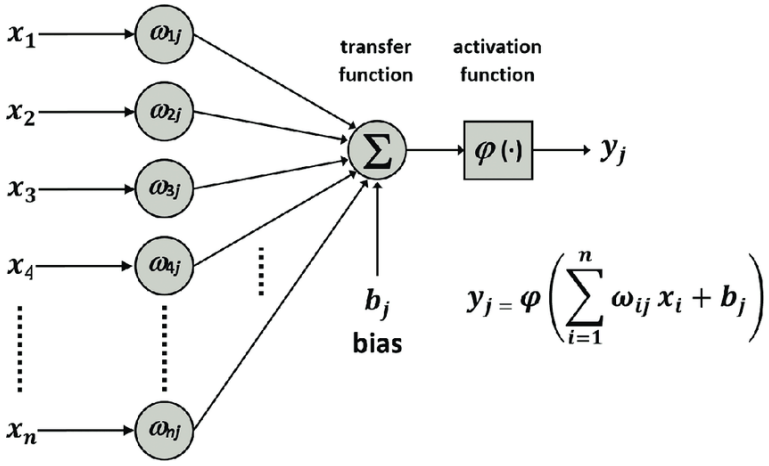

1.2.2 Analyse

Voici les données :

```
#Données de test
N=10 #Nombre d'époques

mean1 = [4, 4]
cov1 = [[1, 0], [0, 1]] #
data1 = np.transpose(np.random.multivariate_normal(mean1, cov1, 128))
mean2 = [-4, -4]
cov2 = [[4, 0], [0, 4]] #
data2 = np.transpose(np.random.multivariate_normal(mean2, cov2, 128))
data=np.concatenate((data1, data2), axis=1)
oracle=np.concatenate((np.zeros(128)-1,np.ones(128)))
```

Dans notre cas la fonction d'activation la sigmoide et nous utiliserons aussi le produit scalaire :

```
def sigmoide(x):#Fonction sigmoide
    z=1/(1+exp(-x))
    return z
```

```
def produit_sc(x,y):
    s=x[0]*y[1]+x[1]*y[2]
    return s
```

Perceptron

```
def perceptron(x,w,active,b):
    y=0
    if(active==0):
        y=sign(b+produit_sc(x,w))#y prend le signe de b+produit_sc(x,w)
    if(active==1):
        if(sigmoide(b+produit_sc(x,w))>=0.5):#
            y=1
        if(sigmoide(b+produit_sc(x,w))<0.5):
            y=-1
    return y
```

Apprentissage

```
def apprentissage(x,yd,active):
    w=[1,-2,4] #Initialisation de w
    mdiff=[]
    b=0.5 #initilalisation
    for j in range(N):# On crée les époque
        r=0 #Après chaque époque l'erreur est initialisé à 0 pour éviter le cumul d'erreur
        for i in range(len(yd)):
            if(perceptron(x[:,i],w,active,b)!=yd[i]):# test si classe prédite par le perceptron est la même que celle désirée
                r=r+4 #erreur (yd_i-y_i)²=(1-(-1))²=(-1-1)²=4
                d=yd[i]-sigmoide(b+produit_sc(x[:,i],w))# Puis on détermine l'erreur d'apprentissage
                [w[1],w[2]]=[w[1],w[2]]+0.1*d*x[:,i] # on fait apprendre les paramètres variant de w
                b=b+0.1*d # puis on fait apprendre le biais

        mdiff.append((r))# Après chaque époque, on range l'erreur cummulée dans une liste mdiff
    print(mdiff)
    return w,mdiff
```

Résultats erreur et données séparées

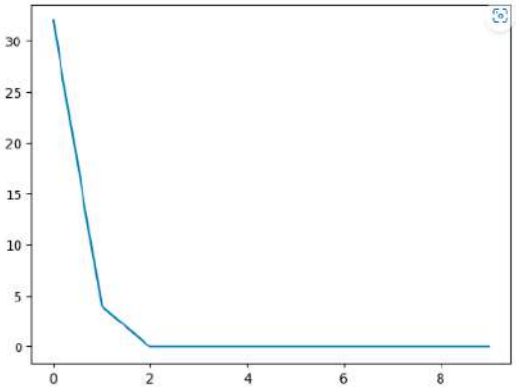

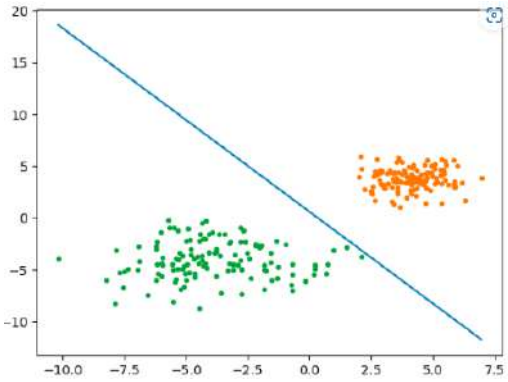

CHAPITRE

2

TP2: CONSTRUCTION D'UN ANTI-SPAM

Avec les machines qui commence à immiter très bien l'intélligence humaines, nous voudrions que celles-ci soient en mesure de détecter si un courier est indésirables ou pas. La construction d'un Anti-Spam est alors un moyen de donner à la machine cette capacité.

2.1 Description

Dans cette partie nous allons mettre en œuvre un Anti-Spam en réalisant des modèles de classifieurs binaires construits à l'aide d'un DataSet (fourni) basé sur les activités normales et anormales d'une messagerie électronique.

Données d'apprentissage et de prédiction

```
#import de la dataset
data=pd.read_csv("Spam detection - For model creation.csv",sep=";")
data
class_le= LabelEncoder()#
data['GOAL-Spam']=class_le.fit_transform(data['GOAL-Spam'].values)# Transforme les données de la colonne GOAL-SPAM qui contient
                                                                  # des No et Yes en 0 pour No et 1 pour Yes
print("Shape is:",data.shape)
data
```

```
Shape is: (2972, 58)
```

```
#Données de prédictions
data_prediction=pd.read_csv("Spam detection - For prediction.csv")
data_prediction
```

Preparations des données

```
x_train=data_prediction.drop('Spam', axis=1) #Dans le fichier data_prédiction on supprime la colonne Spam qui contient
                                             #les valeur de préduction
y_train=data_prediction['Spam']

x_test=data.drop('GOAL-Spam', axis=1)
y_test=data['GOAL-Spam']

print("x_test:", x_test.shape,"y_test",y_test.shape)
print("x_train:", x_train.shape,"y_train",y_test.shape)
```

```
x_test: (2972, 57) y_test (2972,)
x_train: (1274, 57) y_train (2972,)
```

On va ensuite convertir nos données en tableau numpy

```
x_test, y_test=np.array(x_test), np.array(y_test)
x_train, y_train=np.array(x_train), np.array(y_train)
```

2.2 Analyse

2.2.1 Model M1 : Réseau de neurones sans couche cachée

```
model = keras.Sequential()
model.add(keras.layers.Input(57, name="InputLayer"))#Couche d'entrée
model.add(keras.layers.Dense(1, activation="sigmoid"))#Couche de sortie

model.compile(loss=keras.losses.categorical_hinge,
              optimizer="adam",# Nous permet de minimiser l'erreur
              metrics=['accuracy'])
```

```
history = model.fit(x_train,
                    y_train,
                    epochs = 25,#nombre d'époques
                    batch_size = 10)#correction après chaque dizaine
```

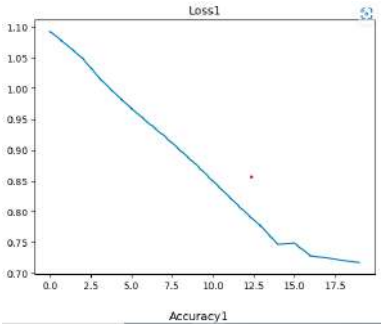

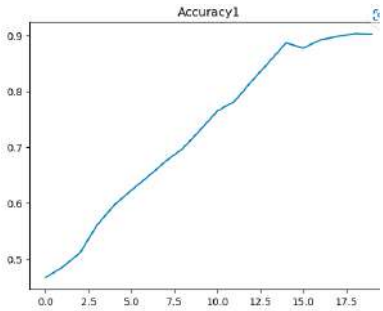

2.2.2 Model M2 : Réseau de neurones avec une couche cachée

```
model = keras.Sequential()
model.add(keras.layers.Input(57, name="InputLayer"))#Couche d'entrée
model.add(keras.layers.Dense(10, activation="sigmoid"))#couche cachée
model.add(keras.layers.Dense(1, activation="sigmoid"))# couche de sortie

model.compile(loss=keras.losses.hinge,# l'erreur loss=keras.losses.hinge
              optimizer="adam",# Nous permet de minimiser l'erreur
              metrics=['accuracy'])
```

```
history = model.fit(x_train,
                    y_train,
                   epochs = 20,
                   batch_size = 10)
```

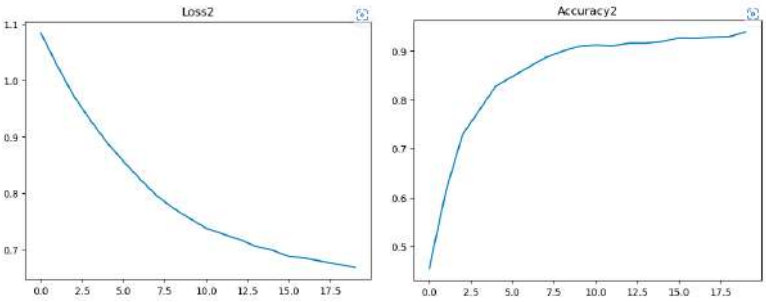

2.2.3 Model M3 : Classifieur Naïf Bayésien

La classification naïve bayésienne est un type de classification bayésienne probabiliste simple basée sur le Théorème de Bayes avec une forte indépendance (dite naïve) des hypothèses.

Construction du classifieur

. Le classifieur bayésien naïf se construit en appliquant une règle de décision couramment employée : la règle du *maximum a posteriori* définie par :

Soit une donnée ***X = (X1=x1, X2=x2, ...Xn=xn)*** à classer.

Alors

$$Classifieur\ (x_1,x_2,\ldots x_n) = ArgMax\ P(C=c_j)\ \pi P(X_i = x_i/C=c_j)$$

```
import scipy.stats
def Clas_Bayes(data):
    esp0    = []
    esp1    = []
    ecar_t0 = []
    ecar_t1 = []
    liste0  = []
    liste1  = []

    for i in range(len(T)): #Dans cette boucle on va créer les listes des indices des élements de classe 0 et 1
        if(T1[i,0]==0):
            liste0.append((i))# On ajoute à liste0 tous les élements de classe 0
        if(T1[i,0]==1):
            liste1.append((i))# On ajoute à liste1 tous les élements de classe 1
    n0=len(liste0) # Cardinal de liste0
    n1=len(liste1) # Cardinal de liste1
    for j in range(len(T.columns)):

        esp0.append((sum(T1[i,j] for i in liste0))/n0)# on calcul l'espérance de chaque critère de détection de spam sachant que
        esp1.append((sum(T1[i,j] for i in liste1))/n1)# on calcul l'espérance de chaque critère de détection de spam sachant que
        ecar_t0.append(sqrt(sum((T1[i,j]-esp0[j])**2 for i in liste0)/(n0-1)))# on calcul la variance de chaque critère de détec
        ecar_t1.append(sqrt(sum((T1[i,j]-esp1[j])**2 for i in liste1)/(n1-1)))# on calcul la variance de chaque critère de détec

    del esp0[0]    # Suppression de l'espérance de classe 0
    del esp1[0]    # Suppression de l'espérance de classe 1
    del ecar_t0[0] # Suppression de l'espérance de classe 0
    del ecar_t1[0] # Suppression de l'espérance de classe 1
```

```
# liste des produit des fonctions densite classe 0
oracle0 = []

for i in range(len(data)):
    p0=n0/len(T) # Probabilité de la classe 0
    for j in range(len(T.columns)-1):
        mu    = esp0[j] # Espérance
        sigma = ecar_t0[j] # Ecart-type
        #f=scipy.stats.norm.pdf(data[i,j],sigma,mu)
        p0 = p0*1/(sigma*sqrt(2*pi))*exp(-0.5*((data[i,j]-mu)/sigma)**2) # produit des fonctions de densité par p0

    oracle0.append((p0))

# liste des produit des fonctions densite classe 1
oracle1 = []

for i in range(len(data)):
    p1 = n1/len(T)# Probalilité de la classe 1
    for j in range(len(T.columns)-1):
        mu    = esp1[j] # Espérance
        sigma = ecar_t1[j] # Ecart-type
        if(mu!=0): #
           #f=scipy.stats.norm.pdf(data[i,j],sigma,mu)
            p1 = p1*1/(sigma*sqrt(2*pi))*exp(-0.5*((data[i,j]-mu)/sigma)**2)# produit des fonctions de densité par p1

    oracle1.append((p1))
```

```
    #classifieur de bayes

    oracle = []
    for i in range(len(data)):#'Lindividu i de data aura la de
        t = 0
        if(oracle1[i]>oracle0[i]):
            t=1
        oracle.append((t))

    return oracle
```

Comparaison

```
# Comparaison des Accuracy (Perfomance de  chaque model)

from sklearn import metrics
accuracy3 = metrics.accuracy_score(data[:,57], Clas_Bayes(data))

print("<<<Accuracy M1:",accuracy_curve1[19],">>> <<<Accuracy M2: ",accuracy_curve2[19],">>> <<<Accuracy M3: ",accuracy3,">>>")
```

```
<<<Accuracy M1: 0.9018838405609131 >>> <<<Accuracy M2:  0.9387755393981934 >>> <<<Accuracy M3:  0.8163265306122449 >>>
```

Après comparaison, le model constuit avec Kéras est le meilleur et l'ajout des couches cachées rend le model plus performant.

CHAPITRE

3

CONCLUSION

Au cours de ces traveaux pratiques, qui étaient pour nous une sorte d'initiation à python, nous avons appris le langage en le mettant en pratique sur les méthodes d'apprentissage supervisée telles que celle des K plus proche voisin, Perceptron, Classifieur Naïf Bayésien. Nous pouvons conclure que l'intelligence artificielle est une grande opportunité à condition que celle-ci soit maîtrisée car nous avons vu travers nos recherche quelques application de la méthode des KPPV (dans le transport par exemple), et des réseaux de neurones dans la détection des de SPAM.

BIBLIOGRAPHIE

[1] **Classifieur Naïf Bayésien** [en ligne]

[2] Cours Apprentissage 2021 - partie1Fichier

[3] **Réseau de neurones avec Kéras**